

Ускорение инференса UNet


Ломовский Роман

Апрель 2026


- Сравнить методы ускорения UNet (сегментация)
- Метрики: латентность (ms), качество (IoU)
- Платформа: GPU (NVIDIA T4)

- UNet (ResNet34 энкодер, предобучен на ImageNet)
- Вход: $224 \times 224 \times 3$
- 21 класс (PASCAL VOC 2012)
- Baseline: FP16

FP16 baseline – латентность



Результат: 7.66 мс (bs=1) ... 61.12 мс (bs=32)



Ускорение до **1.13x** (bs=32).
Качество (IoU) не изменилось.

Операция	Время CUDA (мс)
nchwToNhwc	140.1 (45%)
Winograd conv	20.9 (6.7%)
Batch norm	16.6 (5.3%)

Основные затраты: преобразования форматов и свёртки.

Сравнение всех методов

`all_methods_comparison.png`

Квантизация (PTQ) и спарсификация

- PTQ (int8): ускорение до 20%, падение IoU $\sim 1-2\%$
- Спарсификация (L1, 30%): ускорение $< 5\%$ без sparse тензорных ядер

Сводка (batch size = 32)

Метод	Латентность (мс)	Ускорение
FP16 baseline	61.12	1.00×
torch.compile	54.00	1.13×
ONNX Runtime	53.50	1.14×
TVM	52.80	1.16×
PTQ int8	49.00	1.25×

- FP16 baseline на необученной модели: 0.0011
- После 5 эпох обучения: 0.42 (ожидаемо рост)
- **Вывод:** компиляторы не влияют на IoU; для честного сравнения нужно обучение.

- Компиляторы дают $\sim 10\text{--}15\%$ ускорения
- Квантизация эффективнее ($\sim 25\%$) с небольшим падением качества
- Спарсификация без спец.поддержки неэффективна
- **Планы:** QAT, 2:4 sparsity, TVM с фиксированным batch size