

Ускорение инференса UNet

Ломовский Роман

Апрель 2026

Условия эксперимента

GPU: NVIDIA GeForce RTX 3060 (12 GB VRAM)
CPU: Intel Core i7-12700K
Модель: UNet (ResNet34 энкодер)
Параметры: 24,436,659
Датасет: PASCAL VOC 2012 (3 класса)
Метрика: mIoU = 0.8523

- 1 FP16 baseline (PyTorch Eager)
- 2 torch.compile (reduce-overhead)
- 3 ONNX Runtime (CUDA)
- 4 Пост-тренировочная квантизация (PTQ)
- 5 semi-structured sparsity 2:4
- 6 NNCF + OpenVINO (CPU)

FP16 Baseline (PyTorch Eager)

Batch size	Latency (ms)	Throughput (img/s)
1	7.32	136.6
2	7.70	259.8
4	9.73	411.1
8	17.54	456.2
16	32.13	497.9
32	61.21	522.8

mIoU: 0.8523

Batch size	Latency (ms)	Speedup	Throughput (img/s)
1	7.60	0.96×	131.6
2	7.71	1.00×	259.4
4	9.32	1.04×	429.2
8	16.43	1.07×	486.9
16	29.91	1.07×	534.9
32	54.87	1.12×	583.2

mIoU: 0.8523 (без изменений)

Batch size	Latency (ms)	Speedup	Throughput (img/s)
1	5.25	1.39×	190.5
2	6.33	1.22×	315.9
4	10.23	0.95×	391.0
8	18.62	0.94×	429.6
16	34.14	0.94×	468.7
32	67.18	0.91×	476.3

На малых батчах быстрее, на больших — медленнее baseline.

Post-Training Quantization (dynamic)

Batch size	Latency (ms)	Speedup	Throughput (img/s)
1	8.67	0.84×	115.3
2	8.81	0.87×	227.0
4	10.36	0.94×	386.1
8	17.67	0.99×	452.8
16	31.98	1.00×	500.3
32	61.29	1.00×	522.1

mIoU: 0.8523 (без изменений)

Полуструктурная разреженность 2:4

Batch size	Latency (ms)	Speedup	Throughput (img/s)
1	8.06	0.91×	124.1
2	8.53	0.90×	234.5
4	10.13	0.96×	394.8
8	17.41	1.01×	459.5
16	31.75	1.01×	503.9
32	62.53	0.98×	511.7


Ускорение отсутствует на данной архитектуре. mIoU: 0.8523

NNCF + OpenVINO (Intel CPU)

Batch size	PyTorch FP32 (ms)	OpenVINO INT8 (ms)	Speedup
1	53.14	13.95	3.81×
2	84.46	26.60	3.18×
4	159.03	51.06	3.11×
8	312.85	98.69	3.17×
16	631.22	188.17	3.35×
32	1253.55	368.56	3.40×

mIoU: 0.8519 (-0.05%)

Итоговое сравнение (GPU)



Метод	mIoU	Изменение
FP16 baseline	0.8523	—
torch.compile	0.8523	0.00%
PTQ (dynamic)	0.8523	0.00%
Sparsity 2:4	0.8523	0.00%
NNCF INT8 (OpenVINO)	0.8519	-0.05%

Вывод: Все методы сохраняют качество модели

Сводная таблица (batch size = 32)

Метод	Latency (ms)	Speedup	IoU
FP16 baseline	61.21	1.00×	0.8523
torch.compile	54.87	1.12×	0.8523
ONNX Runtime	67.18	0.91×	—
PTQ (dynamic)	61.29	1.00×	0.8523
Sparsity 2:4	62.53	0.98×	0.8523
OpenVINO INT8 (CPU)	368.56	3.40×	0.8519

- **torch.compile** – простое ускорение до 14% без потери качества
- **ONNX Runtime** – показал небольшое ускорение на GPU на малых батчах
- **PTQ (dynamic)** – не ускоряет из-за специфики модели
- **Sparsity 2:4** – без аппаратной поддержки Ampere+ неэффективен
- **NNCF + OpenVINO** – максимальное ускорение на CPU (до 3.8×)
- **Качество (IoU)** – сохраняется во всех методах (отклонение <0.05%)